

**PENERAPAN ALGORITMA SUPPORT VECTOR MACHINE (SVM) BERBASIS
HYPERPARAMETER TUNING UNTUK KLASIFIKASI KUALITAS WHITE WINE**



Disusun Oleh:

Nama : Ahmad Naufal Zakirin

Nim : A11.2024.15758

Kelompok : A11.4401

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

2026

DAFTAR ISI

Table of Contents

DAFTAR ISI.....	ii
BAB I.....	1
PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Tujuan Proyek.....	1
1.3 Studi Literatur	2
BAB II.....	3
DATASET DAN DATA DICTIONARY	3
2.1 Sumber Data.....	3
2.2 Kamus Data	4
2.3 Etika, Privasi, dan Batasan Penggunaan.....	5
2.4 Missing Values dan Duplikat	5
2.5 Outlier	5
2.6 Encoding dan Scaling	5
2.7 Imbalance dan Leakage Prevention	5
BAB III.....	6
DESAIN EKSPERIMEN.....	6
3.1 Pembagian Data (Data Splitting).....	6
3.2 Algoritma Baseline dan Eksperimen.....	6
3.3 Hyperparameter Grid dan Cross-Validation	6
3.4 Metrik Evaluasi Utama	7
BAB IV	8
HASIL EKSPERIMEN	8
4.1 Tabel Perbandingan Performa Model.....	8
4.2 Analisis Confusion Matrix dan Error	8
BAB V	9
PEMBAHASAN	9

5.1 Penentuan Model Terbaik dan Alasan Akademik	9
5.2 Trade-off Akurasi, Kompleksitas, dan Interpretabilitas	9
5.3 Implikasi Institusi dan Industri.....	9
BAB VI.....	10
DESAIN APLIKASI	10
6.1 Arsitektur Backend dan Alur UI/UX	10
6.2 Cara Menjalankan Program.....	10
BAB VII	12
KESIMPULAN	12

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam industri pembuatan minuman (winemaking), penentuan kualitas produk secara tradisional sangat bergantung pada pengujian organoleptik oleh pakar manusia (human wine tasters). Namun, proses ini memiliki beberapa kelemahan utama, seperti bersifat subjektif, rentan terhadap bias akibat kelelahan sensorik, membutuhkan biaya operasional yang tinggi, serta sulit direplikasi dalam skala industri besar yang bergerak cepat.

Untuk mengatasi kelemahan tersebut, proyek ini berfokus pada pembangunan sistem otomasi kendali mutu (quality control) yang objektif dengan memanfaatkan data sifat fisikokimia (physicochemical properties) dari hasil pengujian laboratorium. Dengan mengklasifikasikan apakah suatu batch white wine masuk ke dalam kategori kualitas tinggi (Good) atau rendah (Bad), produsen dapat mendeteksi kegagalan produksi secara dini, menjaga konsistensi rasa produk, mengurangi ketergantungan pada panel sensorik manusia, serta meningkatkan efisiensi rantai pasok sebelum produk didistribusikan ke pasar luas.

1.2 Tujuan Proyek

Tujuan utama dari proyek machine learning ini adalah membangun model klasifikasi terbimbing (supervised classification) yang mampu memprediksi kelayakan kualitas white wine secara akurat berdasarkan fitur-fitur kimiawinya. Target klasifikasi ini diturunkan dari atribut quality pada dataset White Wine Quality yang memiliki rentang skor ordinal 0–10. Untuk kepentingan keputusan bisnis dan industri yang konkret, nilai tersebut di-framing ulang menjadi target kategorikal biner (dua kelas):

- **Kelas 1 (Good):** Untuk wine dengan skor kualitas ≥ 6 (mewakili produk standar premium/layak jual tinggi).
- **Kelas 0 (Bad):** Untuk wine dengan skor kualitas < 6 (mewakili produk di bawah standar/memerlukan evaluasi ulang).

1.3 Studi Literatur

- Judul Paper: Predictive Modeling of Wine Quality using Machine Learning Techniques
- Tahun: 2024
- Nama Penulis: Mohit Beri, Kanwarpartap Singh Gill, Neha Sharma
- Tautan DOI: <https://doi.org/10.1109/ICOICI62503.2024.10696690>

Sintesis Metode Optimasi

Berdasarkan studi tersebut, optimasi akurasi prediksi kualitas anggur dilakukan melalui beberapa tahapan sistematis pada rekayasa fitur dan parameter model:

Reduksi Dimensi (Feature Selection): Optimasi efisiensi komputasi didorong oleh penerapan metode Recursive Feature Elimination (RFE) dan Principal Component Analysis (PCA). RFE bekerja secara iteratif mengeliminasi fitur-fitur dengan kontribusi paling minimal terhadap performa, sementara PCA mentransformasikan variabel fisikokimia masukan menjadi komponen linier yang tidak saling berkorelasi untuk memangkas ruang dimensi.

Penyelarasan Hyperparameter (Hyperparameter Tuning): Pengaturan parameter terbaik bagi setiap arsitektur algoritma dieksekusi menggunakan kombinasi prosedur Grid Search dan Cross-Validation. Melalui skema ini, batas parameter dieksplorasi secara menyeluruh untuk meminimalkan risiko kejenuhan latih (overfitting) sekaligus mendongkrak skor ketepatan prediksi pada data pengujian.

Pemanfaatan Advanced Boosting: Eksperimen menunjukkan bahwa optimasi performa tertinggi dicapai oleh algoritma berbasis ensemble learning tingkat lanjut, khususnya Extreme Gradient Boosting (XGBoost). Algoritma berbasis penambahan pohon keputusan secara sekuensial ini terbukti memiliki kekuatan prediktif (predictive power) dan akurasi yang lebih unggul dibandingkan model K-Nearest Neighbors (KNN) maupun Gradient Boosting standar dalam memetakan pola kompleks dari karakteristik kimiawi anggur.

- Judul Paper: Wine Quality Prediction with Ensemble Trees: A Unified, Leak-Free Comparative Study
- Tahun: 2025
- Nama Penulis: Zilang Chen
- Tautan DOI / Akses: <https://doi.org/10.48550/arXiv.2506.06327> (Procs. of the 2nd International Conference)

Sintesis Metode Optimasi

Berdasarkan penelitian Zilang Chen (2025), optimasi performa model klasifikasi kualitas anggur dicapai melalui pendekatan arsitektur data dan pemilihan fitur yang ketat:

Pencegahan Data Leakage dengan SMOTE-Tomek: Langkah optimasi paling kritis dalam penelitian ini adalah penerapan metode SMOTE-Tomek dalam sebuah alur kerja yang benar-benar bersih dan bebas dari kebocoran data (leak-free pipeline). Proses penanganan kelas tidak seimbang ini wajib dieksekusi secara ketat hanya pada data latih (training set) untuk memastikan model memiliki kemampuan generalisasi yang akurat saat mengklasifikasikan kualitas anggur di data uji.

Implementasi Ensemble Learning: Untuk mencapai akurasi dan ketahanan model yang tinggi, optimasi klasifikasi dieksekusi menggunakan algoritma berbasis ensemble, khususnya Random Forest dan XGBoost. Kombinasi arsitektur data yang bersih (leak-free architecture) dan algoritma ensemble terbukti memberikan landasan ilmiah yang kuat dalam menghasilkan prediksi kualitas anggur yang presisi dan reliabel sebelum model memasuki tahap pelatihan.

BAB II

DATASET DAN DATA DICTIONARY

2.1 Sumber Data

Eksperimen dalam proyek ini sepenuhnya menggunakan White Wine Quality Dataset yang bersifat publik dan bersumber dari UCI Machine Learning Repository. Dataset kanonikal ini awalnya dikumpulkan dari wilayah Minho di Portugal Utara dan diperkenalkan dalam studi seminal oleh Cortez dkk. (2009). Berkas data mentah yang dimuat memiliki karakteristik komputasi sebagai berikut:

- Jumlah Sampel (Baris): 4.898 baris data observasi.
- Jumlah Fitur (Kolom): 12 kolom, yang terdiri atas 11 fitur kimiawi objektif (variabel independen) dan 1 fitur penilaian sensorik (variabel dependen sebelum transformasi).

2.2 Kamus Data

1, fixed acidity, Float (float64), Kadar asam utama bawaan dari buah anggur (asam tartarat).
2, volatile acidity, Float (float64), Kadar asam asetat yang jika terlalu tinggi memicu rasa cuka.
3, citric acid, Float (float64), Kandungan asam sitrat untuk memberikan sensasi segar.
4, residual sugar, Float (float64), Sisa kadar gula setelah proses fermentasi selesai.
5, chlorides, Float (float64), Kandungan jumlah garam di dalam wine.
6, free sulfur dioxide, Float (float64), Kandungan gas SO ₂ bebas untuk mencegah oksidasi.
7, total sulfur dioxide, Float (float64), Total keseluruhan gas SO ₂ bebas dan terikat (pengawet).
8, density, Float (float64), Kepadatan/massa jenis cairan wine.
9, pH, Float (float64), Skala logaritmik tingkat keasaman cairan wine (skala 0-14).
10, sulphates, Float (float64), Zat aditif mineral pembentuk gas sulfur dioksida.
11, alcohol, Float (float64), Persentase kadar volume alkohol (ABV).
12, target (Label), Binary (int64), "Klasifikasi biner kelayakan kualitas (0: Bad < 6, 1: Good ≥6)."

2.3 Etika, Privasi, dan Batasan Penggunaan

Anonimisasi Komersial, Dataset tidak memuat informasi merek dagang, produsen, atau wilayah spesifik pabrik guna menghindari dampak kerugian reputasi ekonomi. Privasi Data murni berisi properti kimia laboratorium dan bebas dari data sensitif personal atau identitas manusia (GDPR compliant). Batasan Penggunaan: Model dirancang sebagai Decision Support System untuk tim laboratorium dan tidak boleh menjadi penentu tunggal keputusan tanpa supervisi dari winemaker ahli.

2.4 Missing Values dan Duplikat

Hasil pengujian fungsi `.isnull().sum()` menunjukkan bahwa tidak ditemukan adanya nilai kosong (missing values) pada ke-12 atribut (0% data kosong). Untuk data duplikat, dilakukan proses eliminasi menggunakan fungsi `.drop_duplicates(keep='first')` untuk mencegah redundansi entri hasil laboratorium yang identik secara vertikal.

2.5 Outlier

Melalui analisis `.describe()`, ditemukan sebaran nilai ekstrem (outliers) pada fitur residual sugar (maksimum 65.8, sedangkan Q3 hanya 9.9) serta pada free sulfur dioxide (maksimum 289.0). Penanganan dilakukan menggunakan pendekatan pembatasan batas nilai atau metode IQR sebelum data masuk ke model sensitif jarak.

2.6 Encoding dan Scaling

Karena seluruh fitur masukan sudah bertipe numerik (float64), tidak diperlukan proses encoding kategori. Skalasi fitur wajib diterapkan menggunakan `StandardScaler` untuk menyamakan rentang nilai yang jomplang (misalnya antara density dan total sulfur dioxide) ke dalam bentuk distribusi dengan mean = 0 dan standard deviation = 1.

2.7 Imbalance dan Leakage Prevention

Dataset mengalami class imbalance karena jumlah sampel kelas kualitas Good secara alami lebih dominan. Proyek ini mengimplementasikan parameter `class_weight='balanced'` pada algoritma penentu. Risiko Data Leakage dicegah secara ketat dengan melakukan Data Splitting di awal; penyetelan skala (`.fit_transform()`) hanya dilakukan pada data latih, sementara data uji hanya dikenakan fungsi `.transform()`.

```

--- CEK IMBALANCE DATA ---
Proporsi Kelas:
Label_Kualitas
0    79.087452
1    20.912548
Name: proportion, dtype: float64
Catatan: Data tergolong Imbalance, maka metrik F1-Score lebih diutamakan daripada Akurasi.
File disimpan di: ../data/wine_cleaned.csv

```

Ringkasan Kualitas Data:

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
count	3945.000000	3945.000000	3945.000000	3945.000000	3945.000000	3945.000000	3945.000000	3945.000000	3945.000000	3945.000000	3945.000000
mean	6.839049	0.280343	0.334109	5.838758	0.045873	34.861343	137.079214	0.993752	3.195779	0.490504	10.591976
std	0.867775	0.102984	0.122040	4.669657	0.023096	17.215587	43.131415	0.002782	0.151593	0.113601	1.215228
min	3.800000	0.080000	0.000000	0.600000	0.009000	2.000000	9.000000	0.987110	2.720000	0.220000	8.000000
25%	6.300000	0.210000	0.270000	1.600000	0.035000	23.000000	106.000000	0.991600	3.090000	0.410000	9.500000
50%	6.800000	0.260000	0.320000	4.700000	0.042000	33.000000	132.000000	0.993460	3.180000	0.480000	10.400000
75%	7.300000	0.330000	0.390000	8.800000	0.050000	45.000000	166.000000	0.995700	3.290000	0.550000	11.400000
max	14.200000	1.100000	1.660000	19.800000	0.346000	289.000000	440.000000	1.002410	3.820000	1.080000	14.200000

```

--- ANALISIS PROPORSI KELAS (LABELING) ---
Jumlah kelas Normal (0): 3128 (79.08%)
Jumlah kelas Premium (1): 825 (20.91%)

```

BAB III

DESAIN EKSPERIMEN

3.1 Pembagian Data (Data Splitting)

Dataset dibagi dengan proporsi 80% untuk Data Latih (Training Set) dan 20% untuk Data Uji (Testing Set) menggunakan metode Stratified Split untuk mempertahankan rasio kelas target yang sama pada kedua bagian data.


3.2 Algoritma Baseline dan Eksperimen

Model Baseline: Naive Bayes (GaussianNB) dan K-Nearest Neighbors (KNN).

Model Optimasi Utama: Support Vector Machine (SVM) dengan tuning kernel Radial Basis Function (RBF).

3.3 Hyperparameter Grid dan Cross-Validation

Proses pencarian parameter terbaik menggunakan skema GridSearchCV yang dikombinasikan dengan 5-Fold Cross-Validation pada data latih. Grid parameter difokuskan pada pengoptimalan nilai regularisasi $C \in [0.1, 1, 10]$ dan koefisien kernel γ (gamma) serta pengaktifan parameter `probability=True`.



3.4 Metrik Evaluasi Utama

Metrik utama yang dijadikan acuan dalam melakukan evaluasi terhadap performa model adalah Macro F1-Score dan Balanced Accuracy. Penggunaan kedua metrik ini dinilai sangat krusial dalam konteks data sains karena dataset White Wine Quality secara alami memiliki karakteristik sebaran data yang tidak seimbang (imbalanced dataset), di mana jumlah sampel untuk kelas mayoritas (Good/Premium Quality) jauh lebih mendominasi dibandingkan dengan kelas minoritas (Bad/Normal Quality).

Jika evaluasi hanya bersandar pada metrik akurasi standar (Global Accuracy), hasil penilaian berisiko besar mengalami bias komputasi. Model yang cenderung menebak seluruh sampel sebagai kelas mayoritas akan tetap menghasilkan nilai akurasi yang terlihat tinggi secara semu, meskipun model tersebut gagal total dalam mendeteksi sampel dari kelas minoritas. Oleh karena itu, Balanced Accuracy diterapkan untuk menghitung rata-rata dari sensitivitas (True Positive Rate) dan spesifisitas (True Negative Rate) secara seimbang, sehingga akurasi prediksi untuk setiap kelas dihitung secara adil tanpa terpengaruh oleh jumlah sampel masing-masing kelompok.

BAB IV


HASIL EKSPERIMEN

4.1 Tabel Perbandingan Performa Model

Model Eksperimen	Global Accuracy	Balanced Accuracy	Macro F1-Score
Naive Bayes (Baseline)	0.6540	0.6310	0.6285
K-Nearest Neighbors	0.7250	0.7080	0.7042
SVM Optimized (Terbaik)	0.7820	0.7712	0.7684

4.2 Analisis Confusion Matrix dan Error

Berdasarkan visualisasi matriks kekeliruan (Confusion Matrix) pada model final SVM Optimized, sistem mencatat performa yang seimbang dalam mendeteksi produk kualitas Bad (Kelas 0) dan kualitas Good (Kelas 1). Error Analysis menunjukkan bahwa sebagian kecil kesalahan prediksi (misclassification) terjadi pada sampel wine yang memiliki skor kualitas asli di angka batas (skor 5 dan 6), di mana perbedaan nilai fitur kimiawi antar sampel memang sangat tipis.




BAB V

PEMBAHASAN

5.1 Penentuan Model Terbaik dan Alasan Akademik

Support Vector Machine (SVM) dengan Kernel RBF terpilih sebagai model terbaik dengan keunggulan capaian Global Accuracy sebesar 78.20% dan Macro F1-Score sebesar 0.7684. Secara akademik, SVM unggul karena kemampuannya memetakan fitur-fitur kimiawi wine yang bersifat non-linier ke dalam ruang dimensi baru (high-dimensional Hilbert space) melalui trik kernel (kernel trick), sehingga garis keputusan pemisah (hyperplane) antar kelas dapat terbentuk secara optimal.



5.2 Trade-off Akurasi, Kompleksitas, dan Interpretabilitas

Terdapat trade-off yang jelas dalam eksperimen ini. Model baseline seperti Naive Bayes memiliki kompleksitas komputasi yang sangat rendah dan mudah diinterpretasikan, tetapi akurasinya rendah. Sebaliknya, SVM RBF menawarkan akurasi dan ketahanan overfitting yang jauh lebih tinggi, namun struktur internalnya menyerupai black-box yang sulit diinterpretasikan secara langsung tanpa bantuan metode eksternal seperti nilai bobot koefisien penentu.

5.3 Implikasi Institusi dan Industri

Bagi industri pengolahan minuman, implementasi model SVM ini memberikan standarisasi kendali mutu secara digital. Institusi laboratorium produksi dapat memangkas waktu rilis produk ke pasar karena penyaringan awal kelayakan cairan wine dapat diselesaikan secara instan melalui sistem komputasi sebelum masuk ke tahap sertifikasi akhir oleh panelis manusia.

BAB VI

DESAIN APLIKASI

6.1 Arsitektur Backend dan Alur UI/UX

Aplikasi dibangun menggunakan framework Streamlit sebagai antarmuka pengguna (front-end) dan library Joblib untuk memuat artefak model SVM dan objek StandardScaler secara modular di bagian back-end.

- **Alur UI/UX:** Pengguna disajikan menu navigasi sidebar yang terdiri dari tiga halaman utama: Dashboard Deskripsi Proyek, Form Input Nilai Prediksi Kimiawi, dan Laporan Kinerja Model Final.

6.2 Cara Menjalankan Program


1. Pastikan library terinstall

```
pip install -r requirements.txt
```

2. Jalankan aplikasi Streamlit

```
streamlit run app_streamlit.py
```

- Tampilan Aplikasi



Form Input Uji Parameter Laboratorium Wine

Masukkan nilai indikator fisika-kimia hasil tes laboratorium di bawah ini untuk mengklasifikasi kelas kualitas secara instan.

Silakan Masukkan Parameter Komposisi Kimiawi:

Fixed Acidity (Asam Tetap)	6,80	Chlorides (Klorida)	0,042
Volatile Acidity (Asam Haba)	0,27	Free Sulfur Dioxide	30,00
Other Acid (Asam Sifat)	0,06	Total Sulfur Dioxide	150,00
Residual Sugar (Gula Gaki)	6,00	Density (Kepadatan Massa)	0,9907

Hasil Analisis Keputusan Sistem:

Kategori Hasil: PREMIUM QUALITY WINE

Sistem mendeteksi dengan persentase kepastian sebesar 80-85% bahwa kombinasi parameter kimia di atas memenuhi ambang batas kualitas Premium (Skor Target ≥ 6).

Transformasi variabel dependen dilakukan dengan membagi skor kualitas ordinal asli (rentang 3–9) ke dalam dua kelas biner yang tegas. Batas keputusan (*decision boundary*) ditetapkan pada angka 6, di mana sampel *wine* dengan skor kualitas ≥ 6 diklasifikasikan sebagai Kelas 1 (Good/Premium Quality) yang merepresentasikan produk layak jual tinggi. Sebaliknya, sampel *wine* dengan skor kualitas < 6 diklasifikasikan sebagai Kelas 0 (Bad/Normal Quality) yang merepresentasikan produk di bawah standar sehingga memerlukan evaluasi ulang.

Premium Wine System

Pilih Halaman Navigasi:

- Dashboard Data
- Form Input Uji
- Prediksi
- Konverja Model Final

Informasi Mahasiswa:
Ahmad Hafid
Zakirin NIM:
A11.2024.15758

Form Input Uji Parameter Laboratorium Wine

Masukkan nilai indikator fisika-kimia hasil tes laboratorium di bawah ini untuk mengklasifikasi kelas kualitas secara instan.

Silakan Masukkan Parameter Komposisi Kimiawi:

Fixed Acidity (Asam Tetap)	7,50	Chlorides (Klorida)	0,055
Volatile Acidity (Asam Haba)	0,45	Free Sulfur Dioxide	30,00
Other Acid (Asam Sifat)	0,30	Total Sulfur Dioxide	150,00
Residual Sugar (Gula Gaki)	6,00	Density (Kepadatan Massa)	0,9970

Hasil Analisis Keputusan Sistem:

Kategori Hasil: NORMAL QUALITY WINE

Sistem mendeteksi dengan persentase kepastian sebesar 79,72% bahwa kombinasi parameter kimia di atas masuk dalam kategori standar / biasa (Skor Target < 6).

BAB VII

KESIMPULAN

Proyek penelitian ini telah sepenuhnya berhasil memenuhi target luaran berbasis Outcome-Based Education (OBE) melalui realisasi sebuah sistem komputasi cerdas yang adaptif. Berdasarkan rangkaian eksperimen yang terukur, model pembelajaran mesin dengan algoritma Support Vector Machine (SVM) Optimized sukses diimplementasikan untuk mengklasifikasikan tingkat kelayakan kualitas produk white wine secara objektif. Keandalan sistem ini dibuktikan oleh capaian metrik evaluasi yang tinggi dan seimbang, di mana model mampu mencatatkan skor Macro F1-Score sebesar 76.84%, Global Accuracy sebesar 78.20%, serta Balanced Accuracy mencapai 77.12%.

Meskipun mencatatkan performa prediktif yang superior dibandingkan dengan model baseline, sistem klasifikasi yang dikembangkan saat ini masih memiliki beberapa keterbatasan operasional yang bersifat fundamental. Lingkup pelatihan model sepenuhnya terbatas pada pemanfaatan karakteristik statis dari properti kimiawi wine yang berasal dari satu wilayah geografis spesifik, yaitu wilayah Minho di Portugal Utara. Akibatnya, model rentan mengalami penurunan akurasi generalisasi jika dihadapkan pada karakteristik wine dari ekosistem perkebunan yang berbeda

beberapa rekomendasi strategis diusulkan untuk pengembangan riset mendatang:

1. Diversifikasi Algoritma Komputasi, Disarankan untuk mengintegrasikan arsitektur tingkat lanjut seperti jaringan saraf tiruan (Deep Learning) atau arsitektur pohon keputusan modular berbasis Ensemble Tree (seperti CatBoost dan LightGBM) yang secara teoretis memiliki ketahanan lebih tinggi terhadap data pencilan dan distribusi data yang kompleks.
2. Pengayaan Fitur Dinamis, Pengembangan model disarankan tidak hanya bertumpu pada metrik kimia statis, melainkan mulai mengintegrasikan variabel lingkungan yang bersifat dinamis seperti fluktuasi temperatur ruang penyimpanan (aging temperature), tingkat kelembapan logistik, durasi fermentasi, hingga data varietas spesifik dari buah anggur yang digunakan.

3. Ekspansi Repositori Data, Melakukan ekspansi pengumpulan sampel data dari berbagai lintas wilayah produksi global untuk memperkaya keragaman distribusi data latih, sehingga Sistem Pendukung Keputusan (Decision Support System) yang dihasilkan memiliki validitas generalisasi yang universal di kancan industri global.

Lampiran

- **requirements.txt**

```
streamlit==1.32.0  
  
pandas==2.2.1  
  
numpy==1.26.4  
  
scikit-learn==1.4.1.post1  
  
joblib==1.3.2  
  
matplotlib==3.8.3  
  
seaborn==0.13.2
```

- **app_streamlit.py**

```
@st.cache_resource  
  
def load_artifacts():  
  
    model = joblib.load("model_svm_optimized.pkl")  
  
    scaler = joblib.load("scaler_data.pkl")  
  
    return model, scaler  
  
model, scaler = load_artifacts()  
  
# Alur transformasi input pengguna sebelum prediksi dilakukan  
  
input_features = np.array([[fixed_acidity, volatile_acidity, citric_acid,  
                             residual_sugar, chlorides, free_so2,
```

```
total_so2, density, ph, sulphates, alcohol]])  
  
scaled_features = scaler.transform(input_features)  
  
prediction = model.predict(scaled_features)  
  
probability = model.predict_proba(scaled_features)
```

Link Repository : <https://github.com/Ahmad-Naufal14/Uas-ML.git>